Bible Unified

Análisis Matemático del Corpus Bíblico Completo

Investigación exploratoria inductiva

Proyecto Bible Research
`github.com/iafiscal1212/bible_unified`

15 de marzo de 2026 — v3.0

Resumen

Se presenta un análisis matemático exploratorio del corpus bíblico completo: 39 libros del Antiguo Testamento en hebreo (Westminster Leningrad Codex) y 27 libros del Nuevo Testamento en griego (SBLGNT/MorphGNT). El corpus unificado contiene **444,339 palabras** con morfología normalizada.

Fase 1: Seis módulos de análisis independientes —frecuencias, morfología, valores numéricos, estructura, coocurrencia y patrones posicionales— se ejecutaron en paralelo sobre los 66 libros, revelando anomalías significativas: exponente de Zipf atípico en el AT ($s = 0{,}68$), cuasi-igualdad numérica AT/NT ($\approx 0{,}991$), y asimetrías morfológicas pronunciadas.

Fase 2: Cinco investigaciones profundas confirman y extienden estos hallazgos: (i) la anomalía de Zipf del AT persiste al nivel de lemas ($s = 0{,}715$), demostrando estructura semántica —no sólo morfológica— subyacente; (ii) la cuasi-igualdad numérica es estadísticamente significativa ($p = 0{,}0$ por permutación) pero no exacta (IC 95 % no contiene 1.0); (iii) la distribución de longitud de versículos es bimodal, con picos en poesía ($\mu = 9$) y prosa ($\mu = 17$); (iv) se detectan quiebres significativos en el ratio V/N correlacionados con transiciones de género literario; (v) el texto bíblico exhibe autosimilaridad fractal entre niveles jerárquicos (KS $= 0{,}029$, $p = 0{,}301$).

Fase 3: Cuatro investigaciones adicionales: (i) el equilibrio numérico 0.991 está concentrado en 3 letras de alto valor por alfabeto (Gini $> 0{,}70$); (ii) ninguna proximidad a constantes irracionales sobrevive la corrección de Bonferroni (1,172 comparaciones); (iii) el corpus tiene memoria larga (Hurst $H = 1{,}13$, DFA $\alpha = 0{,}82$), significativamente diferente entre AT y NT ($p = 10^{-6}$); (iv) la anomalía de Zipf del AT se concentra en profetas menores cortos, está en la *cola* de la distribución, y correlaciona fuertemente con la densidad verbal ($r = -0{,}55$, $p = 0{,}0003$).

Todos los valores emergen inductivamente del texto; ningún parámetro está hardcodeado.

Índice

1. Introducción y Contexto **4**
1.1. Principio rector: Análisis inductivo . . . 4
1.2. Corpus . . . 4

2. Metodología **4**
2.1. Arquitectura de paralelismo doble . . . 4
2.2. Módulos de análisis . . . 5
2.3. Fase 2: Investigaciones profundas . . . 5
2.4. Fase 3: Investigaciones de tercer nivel . . . 5
2.5. Infraestructura . . . 6

3. Resultados **6**
3.1. Frecuencias y Ley de Zipf . . . 6
3.1.1. Estadísticas léxicas globales . . . 6
3.1.2. Ley de Zipf . . . 6
3.2. Distribuciones Morfológicas . . . 7
3.2.1. Distribución POS global . . . 7
3.2.2. Asimetría verbo/nombre AT vs. NT . . . 7
3.2.3. Bigramas POS dominantes . . . 8
3.3. Valores Numéricos: Gematría e Isopsefía . . . 8
3.3.1. Sistemas de asignación . . . 8
3.3.2. Resultado principal: Cuasi-igualdad AT/NT . . . 8
3.3.3. Estadísticas por versículo . . . 8
3.4. Análisis Estructural . . . 9
3.4.1. Longitud de versículos . . . 9
3.4.2. Proporciones estructurales AT/NT . . . 9
3.4.3. Libros más grandes . . . 9
3.5. Coocurrencia de Lemas . . . 10
3.5.1. Pares más frecuentes . . . 10
3.6. Patrones Posicionales . . . 10
3.6.1. POS de la primera palabra del versículo . . . 10
3.6.2. POS de la última palabra del versículo . . . 11

4. Fase 2: Investigaciones Profundas **11**
4.1. Zipf: ¿Morfología o semántica? . . . 11
4.2. Cuasi-igualdad numérica: significancia estadística . . . 12
4.3. Bimodalidad en longitud de versículos . . . 12
4.4. Quiebres en el ratio V/N por libro . . . 13
4.5. Proporciones y autosimilaridad fractal . . . 13
4.5.1. Ratios AT/NT y constantes irracionales . . . 13
4.5.2. Test de autosimilaridad . . . 14

5. Fase 3: Mecanismos Causales y Cuantificación Fractal **14**
5.1. Mecanismo del equilibrio numérico . . . 14
5.1.1. Contribución por letra . . . 14
5.1.2. Curva de sensibilidad . . . 15

5.1.3. Test de independencia 15
5.2. Constantes algebraicas: corrección de comparaciones múltiples 15
5.3. Dimensión fractal del corpus 16
5.3.1. Dimensión fractal por género literario 16
5.4. Zipf semántico: localización de la anomalía del AT 17
5.4.1. Los libros más anómalos 17
5.4.2. Correlaciones con características del texto 17

6. Discusión: Anomalías y Patrones **17**
6.1. Anomalía 1: Zipf del AT — semántica, localizada en profetas menores . . . 17
6.2. Anomalía 2: Cuasi-igualdad numérica — mecanismo identificado 18
6.3. Anomalía 3: V/N como fingerprint estilístico — confirmada 18
6.4. Patrón 4: Estructura fractal cuantificada 18
6.5. Síntesis: Un corpus con estructura atípica 18

7. Líneas de Investigación Futuras **19**

8. Apéndice: Datos Técnicos **19**
8.1. Gematría hebrea estándar 19
8.2. Repositorio 19

1. Introducción y Contexto

Este proyecto aplica análisis matemático y estadístico al corpus bíblico completo, tratando el texto como un objeto puramente formal: una secuencia de símbolos con estructura jerárquica (palabra $\subset$ versículo $\subset$ capítulo $\subset$ libro $\subset$ corpus).

1.1. Principio rector: Análisis inductivo

No se parte de hipótesis previas sobre qué patrones "deberían" existir. Los módulos de análisis calculan métricas base y dejan que la inspección posterior identifique anomalías estadísticas. Cualquier patrón reportado *emerge* de los datos.

1.2. Corpus

Cuadro 1: Composición del corpus unificado

	AT Hebreo	**NT Griego**	**Total**
Libros	39	27	66
Capítulos	929	260	1,189
Versículos	23,213	7,927	31,140
Palabras	306,785	137,554	444,339
Fuente	WLC (OSHB)	SBLGNT (MorphGNT)	—

Cada palabra del corpus contiene: texto original, lema normalizado, código morfológico, parte del discurso normalizada (POS), y metadatos posicionales (libro, capítulo, versículo, posición).

2. Metodología

2.1. Arquitectura de paralelismo doble

El análisis emplea paralelismo en dos dimensiones:

1. **Por tipo de patrón**: 6 módulos independientes ejecutados como subprocesos simultáneos por el `orchestrator.py`.
2. **Por libro**: Dentro de cada módulo, `multiprocessing.Pool` procesa los 66 libros en paralelo.

2.2. Módulos de análisis

Cuadro 2: Los 6 módulos de análisis

Módulo	Métricas principales
`frequencies`	Frecuencias absolutas/relativas, Zipf, hapax, TTR
`morphology`	Distribuciones POS, ratio V/N, bigramas POS
`numerical`	Gematría hebrea, isopsefía griega, sumas por versículo/capítulo
`structure`	Longitudes, momentos estadísticos, proporciones
`cooccurrence`	Coocurrencia de lemas, PMI (Pointwise Mutual Information)
`positional`	Patrones primera/última palabra, POS por posición

2.3. Fase 2: Investigaciones profundas

A partir de las anomalías detectadas en Fase 1, se diseñaron 5 investigaciones estadísticas dirigidas, ejecutadas por `orchestrator_fase2.py`:

Cuadro 3: Los 5 módulos de Fase 2

Módulo	Pregunta de investigación
`deep_zipf`	¿La anomalía de Zipf del AT es morfológica o semántica?
`deep_numerical`	¿El ratio numérico 0.991 es estadísticamente significativo?
`deep_bimodal`	¿La distribución de longitud de versículos es bimodal?
`deep_vn_ratio`	¿Dónde se quiebra el ratio V/N y qué lo correlaciona?
`deep_proportions`	¿El corpus exhibe autosimilaridad fractal?

2.4. Fase 3: Investigaciones de tercer nivel

A partir de los resultados de Fase 2, se diseñaron 4 investigaciones que profundizan en los mecanismos causales y cuantifican propiedades fractales, ejecutadas por `orchestrator_fase3.py`:

Cuadro 4: Los 4 módulos de Fase 3

Módulo	Pregunta de investigación
`deep_numerical_mechanism`	¿Qué letras específicas producen el equilibrio 0.991?
`deep_algebraic_constants`	¿Los ratios AT/NT $\approx \sqrt{5}$ sobreviven Bonferroni?
`deep_fractal`	¿Cuál es la dimensión fractal real (Hurst, DFA)?
`deep_zipf_semantic`	¿Qué libros y POS concentran la anomalía de Zipf?

2.5. Infraestructura

- Servidor Hetzner dedicado: 20 cores, 64 GB RAM, Ubuntu 24.04
- Fase 1: **7 segundos** (6 módulos en paralelo)
- Fase 2: **45 segundos** (5 investigaciones con permutaciones y bootstrap)
- Fase 3: **116 segundos** (4 investigaciones con bootstrap × 10K y análisis fractal)
- Dependencias: Python 3.12, NumPy, Pandas, SciPy, scikit-learn (GMM)

3. Resultados

3.1. Frecuencias y Ley de Zipf

3.1.1. Estadísticas léxicas globales

Cuadro 5: Diversidad léxica del corpus

	AT	**NT**	**Global**
Tokens (palabras)	306,785	137,554	444,339
Tipos (word-forms)	112,072	19,335	131,407
Tipos (lemas)	9,524	5,461	14,985
Hapax legomena (words)	—	—	90,782
Hapax legomena (lemas)	—	—	5,150
Hapax / tipos (words)	—	—	69.1 %
Hapax / tipos (lemas)	—	—	34.4 %

Observación clave: El 69 % de las formas de palabra aparecen exactamente una vez (*hapax legomena*). El AT hebreo contribuye desproporcionadamente: con 2.23× más tokens, tiene 5.8× más word-types, reflejando la riqueza morfológica aglutinante del hebreo bíblico.

3.1.2. Ley de Zipf

La ley de Zipf predice que la frecuencia de la r-ésima palabra más común es proporcional a r^{-s}, con $s \approx 1{,}0$ para lenguas naturales típicas.

Cuadro 6: Ajuste de Zipf: $\log f = a - s \cdot \log r$

Corpus	**Exponente** s	R^2
Global	0.734	0.918
AT (hebreo)	**0.679**	0.907
NT (griego)	**0.976**	0.962

Anomalía del AT. El exponente $s = 0{,}679$ del AT se desvía significativamente del valor canónico $s \approx 1$. Esto indica una *cola más pesada*: hay proporcionalmente más palabras de frecuencia intermedia de lo que Zipf predice. Hipotesis candidatas:

1. **Morfología aglutinante**: Los prefijos hebreos (*be-*, *ha-*, *we-*) generan múltiples formas de superficie para cada lema, inflando la zona media del ranking.
2. **Vocabulario técnico repetido**: Las secciones legales (Levítico, Deuteronomio) y genealógicas repiten vocabulario especializado con frecuencia intermedia.
3. **Heterogeneidad de género**: El AT mezcla narrativa, poesía, ley y profecía, cada uno con su propio vocabulario, produciendo superposición de distribuciones.

NT canónico. El NT griego ($s = 0{,}976$, $R^2 = 0{,}962$) se ajusta casi perfectamente a Zipf, comportamiento típico de un corpus lingüístico homogéneo.

3.2. Distribuciones Morfológicas

3.2.1. Distribución POS global

Cuadro 7: Distribución de partes del discurso

POS	Frecuencia	%
Nombre (noun)	148,415	33.4 %
Verbo (verb)	94,088	21.2 %
Sufijo pronominal	47,824	10.8 %
Partícula	28,506	6.4 %
Conjunción	24,605	5.5 %
Preposición	23,908	5.4 %
Pronombre	23,831	5.4 %
Adjetivo	23,194	5.2 %
Artículo	19,770	4.5 %
Adverbio	10,180	2.3 %

3.2.2. Asimetría verbo/nombre AT vs. NT

Cuadro 8: Ratio verbo/nombre por corpus

Corpus	Ratio V/N
AT (hebreo)	**0.55**
NT (griego)	**0.99**
Global	0.63

El AT es fuertemente **nominal** (casi 2 nombres por cada verbo), mientras que el NT tiene equilibrio prácticamente 1:1. Esto refleja:

- AT: estilo genealogico-descriptivo, constructos nominales encadenados (*semikhut*)
- NT: estilo argumentativo-discursivo, oraciones verbales complejas (koiné griega)

3.2.3. Bigramas POS dominantes

El bigrama más frecuente es **nombre→nombre** con 54,207 ocurrencias, reflejando las cadenas de constructo del hebreo (*"hijo-de-David rey-de-Israel"*). El segundo lugar lo ocupa **verbo→nombre** (26,255), el patrón narrativo básico.

3.3. Valores Numéricos: Gematría e Isopsefía

3.3.1. Sistemas de asignación

- **Gematría hebrea**: $\aleph = 1, \beth = 2, \ldots, \tau = 400$ (sistema estándar, formas finales = mismo valor)
- **Isopsefía griega**: $\alpha = 1, \beta = 2, \ldots, \omega = 800$ (sistema clásico con digamma=6, koppa=90)

3.3.2. Resultado principal: Cuasi-igualdad AT/NT

Cuadro 9: Valores numéricos totales por corpus

Corpus	Valor total	
AT (gematría)	78,482,867	
NT (isopsefía)	79,203,470	
Ratio AT/NT	**0.9909**	
Diferencia	720,603	(0.91 %)

Interpretación. A pesar de que el AT tiene 2,23× más palabras que el NT, los valores numéricos totales son prácticamente idénticos (diferencia $< 1\,\%$). Esto ocurre porque el alfabeto griego asigna valores más altos (máximo $\omega = 800$) que el hebreo (máximo $\tau = 400$), compensando exactamente la menor cantidad de texto.

Pregunta abierta: ¿Es esta cuasi-igualdad una consecuencia trivial de las proporciones alfabéticas, o existe una invariancia más profunda? Un test de permutación (bootstrap) puede distinguir ambas hipótesis.

3.3.3. Estadísticas por versículo

Cuadro 10: Valores numéricos por versículo (global)

Métrica	Valor
Número de versículos	31,140
Media	5,063.8
Mediana	3,855
Mínimo	160
Máximo	32,312
Percentil 25	2,376
Percentil 75	6,386

3.4. Análisis Estructural

3.4.1. Longitud de versículos

Cuadro 11: Momentos estadísticos de la longitud de versículo (en palabras)

Momento	**Valor**
Media (μ)	14.27
Mediana	13
Desviación estándar (σ)	6.44
Asimetría (skewness)	+0.76
Curtosis (excess)	+0.53
Mínimo	2
Máximo	58
P10	7
P90	23

La distribución tiene asimetría positiva ($\gamma_1 = 0{,}76$): cola derecha extendida. La curtosis ligeramente positiva ($\kappa = 0{,}53$) indica un pico más agudo que la distribución normal, con colas algo más pesadas.

3.4.2. Proporciones estructurales AT/NT

Cuadro 12: Proporciones entre AT y NT

Métrica	**AT**	**NT**	**Ratio AT/NT**
Palabras	306,785	137,554	2.230
Versículos	23,213	7,927	2.928
Capítulos	929	260	3.573

Patrón jerárquico. Los ratios AT/NT crecen al subir en la jerarquía: 2,23 → 2,93 → 3,57 (palabras → versículos → capítulos). Esto implica que los versículos del NT son en promedio más largos (17.35 palabras/verso) que los del AT (13.22 palabras/verso), y los capítulos del NT contienen más versículos.

3.4.3. Libros más grandes

Cuadro 13: Top 5 libros por número de palabras

#	**Libro**	**Palabras**
1	Jeremías	21,976
2	Génesis	20,629
3	Salmos	19,657
4	Lucas	19,446
5	Ezequiel	18,866

3.5. Coocurrencia de Lemas

Se analizaron 688,150 pares únicos de lemas que coocurren en al menos un versículo.

3.5.1. Pares más frecuentes

Cuadro 14: Top 10 pares de lemas coocurrentes (por frecuencia)

#	Lema A	Lema B	Coocurrencias
1	*kai* (y)	*ho* (el)	4,568
2	*autos* (él)	*ho* (el)	3,427
3	*autos* (él)	*kai* (y)	2,735
4	*de* (pero)	*ho* (el)	2,245
5	YHWH (3068)	*'et* (853)	2,125
6	*'el* (a) [413]	*'amar* (dijo) [559]	2,107
7	*'asher* (que) [834]	*'et* (853)	2,001
8	*en* (en)	*ho* (el)	1,912
9	*eimi* (ser)	*ho* (el)	1,868
10	*lego* (decir)	*ho* (el)	1,826

Los pares del NT dominan el ranking global debido a la alta frecuencia del artículo *ò* en griego. En el AT, el par dominante es YHWH + marcador de objeto directo (*'et*), reflejando la construcción "[verbo] a YHWH".

3.6. Patrones Posicionales

3.6.1. POS de la primera palabra del versículo

Cuadro 15: POS de la primera palabra de cada versículo

POS	Frecuencia	%
Verbo	12,668	40.7 %
Nombre	4,977	16.0 %
Conjunción	4,245	13.6 %
Partícula	2,265	7.3 %
Pronombre	1,478	4.7 %
Sufijo	1,477	4.7 %
Adverbio	1,423	4.6 %

Patrón narrativo. El 40.7 % de los versículos comienzan con un **verbo**, reflejando la estructura *wayyiqtol* del hebreo narrativo ("Y dijo...", "Y fue...") y construcciones similares en el NT griego. Esto es un rasgo tipológico fundamental del estilo bíblico.

3.6.2. POS de la última palabra del versículo

Cuadro 16: POS de la última palabra de cada versículo

POS	Frecuencia	%
Nombre	12,810	41.1 %
Sufijo pron.	7,090	22.8 %
Verbo	6,138	19.7 %
Pronombre	2,398	7.7 %
Adjetivo	1,980	6.4 %

Complementariedad posicional. Existe una clara **complementariedad**: los versículos *abren con verbo* (40.7 %) y *cierran con nombre* (41.1 %) + sufijo pronominal (22.8 %). La preposición casi nunca cierra un versículo (0.02 %), como era esperable.

4. Fase 2: Investigaciones Profundas

Las cinco investigaciones de esta sección responden directamente a las anomalías y preguntas abiertas de la Fase 1.

4.1. Zipf: ¿Morfología o semántica?

Se recalculó el exponente de Zipf sobre *lemas* (eliminando la variación morfológica de superficie) y se comparó con el ajuste sobre formas de superficie, libro por libro.

Cuadro 17: Exponente de Zipf: formas de superficie vs. lemas

Corpus	Superficie (s)	Lemas (s)	Δs
AT (hebreo)	0.801	**0.715**	−0,046
NT (griego)	0.838	**1.078**	−0,238

Resultado.

- El **NT** se normaliza perfectamente a $s \approx 1{,}08$ al usar lemas: la desviación en superficie era **puramente morfológica**.
- El **AT** *sigue anómalo* en lemas ($s = 0{,}715$): hay **estructura semántica subyacente** que desvía la distribución, no explicable por morfología.
- El CV de Δs en el AT es 1.95 (alta variabilidad entre libros): la anomalía no es uniforme sino específica de ciertos libros.
- Mann-Whitney AT vs. NT sobre Δs: $p = 0{,}0$ (diferencia extremadamente significativa).

Implicación. El AT hebreo tiene una estructura léxica *sui generis*: incluso al nivel de lemas, la distribución de frecuencias se desvía del comportamiento zipfiano canónico. Esto apunta a una organización semántica del vocabulario diferente a la de cualquier corpus lingüístico homogéneo.

4.2. Cuasi-igualdad numérica: significancia estadística

Se ejecutaron tres tests para determinar si el ratio gematría/isopsefía = 0,991 es trivial o significativo.

Cuadro 18: Tests estadísticos sobre el ratio numérico AT/NT

Test	Resultado	Interpretación
Permutación (10K)	$p = 0{,}0$	Ninguna permutación produce ratio tan cercano a 1
Bootstrap IC 95 %	[0,986, 0,996]	**No contiene 1.0**
Ratio teórico	0.922	Si letras fueran uniformes
Ratio observado	**0.991**	

Veredicto. El ratio 0.991 es **doblemente significativo**:

1. Es significativamente más cercano a 1.0 que el azar ($p = 0{,}0$).
2. Pero **no es exactamente 1.0** (el IC 95 % no lo contiene).
3. El ratio teórico bajo letras uniformes (0.922) está lejos del observado: la cuasi-igualdad no es una propiedad trivial de los alfabetos.

La cuasi-igualdad numérica AT/NT es un **fenómeno real**, no explicable por las proporciones de los alfabetos ni por el azar.

4.3. Bimodalidad en longitud de versículos

Se clasificó cada versículo por género literario y se ajustó un modelo de mezcla gaussiana (GMM) a la distribución global de longitudes.

Cuadro 19: Longitud media por género literario

Género	Media (pal/verso)	N versículos
Poético	**9.05**	3,092
Narrativo	13.85	20,389
Epistolar	17.31	5,692
Legal	**18.02**	1,967

GMM de 2 componentes.

- Componente 1: $\mu_1 = 9{,}03$, $\sigma_1 = 2{,}7$, peso = 35,4 %
- Componente 2: $\mu_2 = 17{,}15$, $\sigma_2 = 6{,}08$, peso = 64,6 %

- Mejora BIC: **3,482 puntos** ⇒ el modelo bimodal es masivamente superior
- Mann-Whitney entre todos los pares de géneros: $p < 0{,}003$ en todos los casos

Los dos picos del GMM corresponden exactamente a **poesía** ($\mu \approx 9$) vs. **narrativa/legal/epistolar** ($\mu \approx 17$). La bimodalidad es una huella estadística de la *dualidad verso poético / oración prosaica* que estructura el corpus bíblico.

4.4. Quiebres en el ratio V/N por libro

Se analizó la serie V/N (verbo/nombre) de los 66 libros en orden canónico, buscando *changepoints* significativos (test t con $p < 0{,}001$).

Cuadro 20: Changepoints significativos en la serie V/N

Pos.	Entre...	V/N antes → después	p
#38	Zacarías → Malaquías	0,598 → 0,864	$5{,}3 \times 10^{-5}$
#17	Ester → Job	0,513 → 0,780	$7{,}5 \times 10^{-5}$
#24	Jeremías → Lamentaciones	0,562 → 0,796	$9{,}0 \times 10^{-5}$
#31	Abdías → Jonás	0,587 → 0,821	$9{,}7 \times 10^{-5}$

Correlaciones con otras métricas.

- V/N vs. tasa de hapax: $r = -0{,}39$, $p = 0{,}001$ (más verbos ⇒ menos hapax)
- V/N vs. exponente Zipf: $r = 0{,}35$, $p = 0{,}004$ (más verbos ⇒ Zipf más canónico)
- V/N vs. tamaño de libro: $r = 0{,}001$, $p = 0{,}99$ (sin relación)

Los quiebres coinciden con transiciones de género literario bien conocidas: Ester→Job marca el paso de narrativa histórica a literatura sapiencial; Jeremías→Lamentaciones, de profecía en prosa a poesía elegíaca. El ratio V/N funciona como un **fingerprint estilístico** cuantitativo.

4.5. Proporciones y autosimilaridad fractal

4.5.1. Ratios AT/NT y constantes irracionales

Cuadro 21: Proximidad de los ratios AT/NT a constantes irracionales

Nivel	Ratio AT/NT	Constante más cercana	Distancia
Palabras	2.230	$\sqrt{5} = 2{,}236$	**0.006**
Versículos	2.928	$e = 2{,}718$	0.210
Capítulos	3.573	$\pi = 3{,}142$	0.431
Libros	1.444	$\sqrt{2} = 1{,}414$	0.030

Nota. La proximidad a nivel de palabras ($|2{,}230 - \sqrt{5}| = 0{,}006$) y de libros ($|1{,}444 - \sqrt{2}| = 0{,}030$) es notable, pero las proximidades a nivel de versículos y capítulos son débiles. No se afirma relación causal con constantes matemáticas; se reporta como observación descriptiva.

4.5.2. Test de autosimilaridad

Se comparó la distribución normalizada de longitudes de versículos dentro de cada capítulo con la distribución normalizada de longitudes de capítulos dentro de cada libro, mediante un test de Kolmogorov-Smirnov.

Resultado: KS = 0,029, $p = 0{,}301$.

Las distribuciones normalizadas son **estadísticamente indistinguibles** ($p > 0{,}05$). El texto bíblico exhibe **autosimilaridad fractal** entre niveles jerárquicos: la forma de la variación es la misma ya sea que se mire hacia adentro (versículos en capítulos) o hacia afuera (capítulos en libros).

5. Fase 3: Mecanismos Causales y Cuantificación Fractal

Las cuatro investigaciones de esta sección profundizan en los *mecanismos* subyacentes a las anomalías confirmadas en Fase 2, y cuantifican por primera vez las propiedades fractales del corpus.

5.1. Mecanismo del equilibrio numérico

Se descompuso el total gematría/isopsefía letra por letra para identificar qué caracteres específicos producen el ratio 0,991.

5.1.1. Contribución por letra

Cuadro 22: Top 3 letras contribuyentes al total numérico

	Letra	Valor	Frecuencia	Contribución
AT		400	63,583	25,433,200
AT		300	58,451	17,535,300
AT		200	68,365	13,673,000
NT	ω	800	21,327	17,061,600
NT	υ	400	39,549	15,819,600
NT	τ	300	51,039	15,311,700

Concentración.

- Las top-3 letras del **AT** producen el **72.2 %** del total de gematría.
- Las top-3 letras del **NT** producen el **60.9 %** del total de isopsefía.
- Coeficiente de Gini: **AT** = 0,75, **NT** = 0,70 $\Rightarrow$ el equilibrio es **concentrado en pocas letras de alto valor**, no distribuido.

5.1.2. Curva de sensibilidad

Cuadro 23: Ratio AT/NT al eliminar el $X\,\%$ de letras de mayor contribución

% eliminado	Ratio restante	Δ vs. 0.991
0 %	0.991	—
10 %	0.767	−0,224
20 %	0.775	−0,216
30 %	0.778	−0,213
40 %	1.212	+0,221
50 %	1.192	+0,201

Eliminar tan solo el 10 % de letras de mayor contribución destruye la cuasi-igualdad (ratio cae a 0.77). Esto confirma que el equilibrio depende críticamente de las letras , , en hebreo y ω, υ, τ en griego.

5.1.3. Test de independencia

Las distribuciones de frecuencia de letras por clase de valor (unidades, decenas, centenas) son **significativamente diferentes** entre AT y NT ($\chi^2 = 77{,}560$, $p \approx 0$, dof $= 3$). El equilibrio no proviene de distribuciones similares sino de una *compensación accidental* entre valores altos del griego y volumen de texto del hebreo.

5.2. Constantes algebraicas: corrección de comparaciones múltiples

Se buscó sistemáticamente en un espacio de 293 constantes algebraicas y transcendentales ($\sqrt{n}$, $\sqrt[3]{n}$, $(\sqrt{n}+\sqrt{m})/k$, π, e, φ, $\ldots$), generando 1,172 comparaciones (293 constantes $\times$ 4 ratios).

Cuadro 24: Proximidad a constantes algebraicas tras corrección de Bonferroni

Nivel	Ratio	Constante más cercana	$p_{\text{Bonf.}}$	Sig.
Palabras	2.230	$(\sqrt{4}+\sqrt{6})/2 = 2{,}225$	1.0	NO
Versículos	2.928	$(\sqrt{8}+\sqrt{9})/2 = 2{,}914$	1.0	NO
Capítulos	3.573	$\sqrt{13} = 3{,}606$	1.0	NO
Libros	1.444	$\sqrt[3]{3} = 1{,}442$	1.0	NO

Veredicto. Ninguna proximidad sobrevive la corrección de Bonferroni. La cercanía a $\sqrt{5}$ reportada en Fase 2 ($d = 0{,}006$) es un artefacto de comparaciones múltiples: con 1,172 comparaciones, distancias de esa magnitud son esperables por azar. Se retira esta observación como hallazgo.

Progresiones. Los ratios (1.44, 2.23, 2.93, 3.57) forman una **progresión aritmética** (diferencias sucesivas: 0.79, 0.70, 0.64, CV bajo), no geométrica. Esto indica que la "ganancia" de AT sobre NT crece linealmente con el nivel jerárquico, no exponencialmente.

5.3. Dimensión fractal del corpus

Se aplicaron tres métodos independientes a la serie temporal de longitudes de versículo (31,140 puntos):

Cuadro 25: Análisis fractal: tres métodos independientes

Métrica	**Global**	**AT**	**NT**
Box-counting D_f	0.825	0.834	0.787
Hurst H (R^2)	**1.126** (0.994)	**1.110** (0.987)	**0.993** (0.989)
DFA α (R^2)	**0.823** (0.988)	**0.846** (0.986)	**0.681** (0.988)

Interpretación.

- $H > 0{,}5$ y $\alpha > 0{,}5$ en todos los casos $\Rightarrow$ **memoria larga confirmada**. Versículos largos tienden a estar cerca de versículos largos (persistencia).
- $H \approx 1{,}1$ en el AT indica *fuerte persistencia*, típica de procesos con memoria larga similar a ruido $1/f$.
- AT vs. NT son **significativamente diferentes** ($p = 10^{-6}$ por bootstrap t-test): el AT tiene memoria más larga que el NT.

5.3.1. Dimensión fractal por género literario

Cuadro 26: Exponentes fractales por género

Género	**Hurst H**	**DFA α**
Narrativo	**1.065**	0.818
Poético	0.934	0.776
Epistolar	0.740	0.642
Legal	0.677	0.650

La **narrativa** tiene la memoria más larga ($H = 1{,}07$), coherente con la estructura secuencial de la prosa histórica (escenas que mantienen longitud similar). La literatura **legal** tiene la menor ($H = 0{,}68$), reflejando la naturaleza más "atómica" de las leyes individuales. Todos los géneros tienen $\alpha > 0{,}5$, confirmando correlaciones de largo alcance en todo el corpus.

5.4. Zipf semántico: localización de la anomalía del AT

5.4.1. Los libros más anómalos

Cuadro 27: Top 5 libros del AT con menor exponente Zipf en lemas

#	Libro	s (lemas)	Zona de la anomalía
1	Nahúm	**0.501**	cola
2	Abdías	**0.530**	cola
3	Habacuc	**0.577**	cola
4	Proverbios	0.583	cola
5	Cantar de los Cantares	0.586	cola

Hallazgo clave. La anomalía está **siempre en la cola** (frecuencias medias-bajas), no en la cabeza. Los libros más anómalos son *profetas menores cortos* y *literatura sapiencial*: textos con vocabulario especializado y repetitivo en la zona media de frecuencias.

5.4.2. Correlaciones con características del texto

Cuadro 28: Correlaciones del exponente Zipf (s) con características del libro

Variable	Pearson r	p	Interpretación
% verbos	$-0{,}545$	0.0003	Más verbos $\Rightarrow$ Zipf más anómalo
% nombres	$+0{,}377$	0.018	Más nombres $\Rightarrow$ Zipf más canónico
Tamaño (tokens)	$+0{,}612$	$3{,}4 \times 10^{-5}$	Libros cortos $\Rightarrow$ más anómalos
Long. media verso	$+0{,}281$	0.084	No significativo

Mecanismo propuesto. La anomalía de Zipf del AT se explica por dos factores:

1. **Tamaño**: Los libros cortos tienen muestras insuficientes para que la ley de Zipf se manifieste plenamente ($r = 0{,}61$, $p < 10^{-4}$).
2. **Densidad verbal**: Los libros con mayor proporción de verbos presentan Zipf más anómalo ($r = -0{,}55$, $p = 0{,}0003$), sugiriendo que el vocabulario verbal hebreo tiene una distribución de frecuencias intrínsecamente diferente a la nominal.

Los verbos del AT ($\bar{s}_{\text{verbo}} = 0{,}72$) son ligeramente más anómalos que los nombres ($\bar{s}_{\text{nombre}} = 0{,}75$), aunque la diferencia no alcanza significancia estadística ($p = 0{,}35$). La entropía de Shannon correlaciona marginalmente con s ($r = 0{,}31$, $p = 0{,}059$): los libros anómalos tienden a distribuciones menos uniformes.

6. Discusión: Anomalías y Patrones

6.1. Anomalía 1: Zipf del AT — semántica, localizada en profetas menores

La Fase 1 detectó $s = 0{,}679$ para el AT. La Fase 2 demostró que persiste en lemas ($s = 0{,}715$): es semántica, no morfológica. La Fase 3 (§5.4) *localiza* la anomalía: se concentra en

profetas menores cortos (Nahúm $s = 0{,}50$, Abdías $s = 0{,}53$) y **literatura sapiencial** (Proverbios $s = 0{,}58$). El mecanismo es doble: libros cortos con alta densidad verbal. La anomalía está siempre en la *cola* (frecuencias medias), no en la cabeza de la distribución.

6.2. Anomalía 2: Cuasi-igualdad numérica — mecanismo identificado

La Fase 2 confirmó que el ratio 0,991 es significativo ($p = 0{,}0$) y no trivial. La Fase 3 (§5.1) identifica el **mecanismo causal**: el equilibrio está concentrado en pocas letras de alto valor (Gini $> 0{,}70$). Tres letras por alfabeto (// en hebreo; $\omega/\upsilon/\tau$ en griego) producen el 60–72 % de los totales. Las distribuciones de frecuencia son significativamente diferentes ($\chi^2 = 77{,}560$), por lo que se trata de una **compensación accidental**: los valores altos del griego compensan el mayor volumen del hebreo.

6.3. Anomalía 3: V/N como fingerprint estilístico — confirmada

La Fase 2 (§4.4) confirma que el ratio V/N presenta **quiebres significativos** que coinciden con transiciones de género literario. La Fase 3 (§5.4) añade que el ratio V/N correlaciona directamente con el exponente de Zipf: libros con más verbos tienen Zipf más anómalo ($r = -0{,}55$, $p = 0{,}0003$), estableciendo un **vínculo cuantitativo** entre estilo y estructura léxica.

6.4. Patrón 4: Estructura fractal cuantificada

1. **Bimodalidad** (§4.3): Confirmada con GMM (ΔBIC $= 3{,}482$).
2. **Memoria larga** (§5.3): Hurst $H = 1{,}13$ y DFA $\alpha = 0{,}82$, ambos $> 0{,}5$ con $R^2 > 0{,}98$. Tres métodos independientes convergen: el corpus tiene **correlaciones de largo alcance** en la serie de longitudes de versículo. El AT ($H = 1{,}11$) tiene memoria significativamente más larga que el NT ($H = 0{,}99$, $p = 10^{-6}$).
3. **Constantes irracionales descartadas** (§5.2): La proximidad a $\sqrt{5}$ de Fase 2 no sobrevive Bonferroni (1,172 comparaciones). Los ratios forman una progresión aritmética, no geométrica.

6.5. Síntesis: Un corpus con estructura atípica

Las tres fases de análisis convergen en una imagen coherente del corpus bíblico:

- **Anomalía léxica localizada**: El AT tiene Zipf anómalo por libros cortos con alta densidad verbal (profetas, sabiduría). El NT es canónico.
- **Equilibrio numérico concentrado**: El ratio 0.991 es real pero depende de 6 letras de alto valor. Es una compensación accidental, no una propiedad profunda.
- **Memoria larga con jerarquía de géneros**: La narrativa tiene la memoria más larga ($H = 1{,}07$), la legislación la menor ($H = 0{,}68$). Todos los géneros son persistentes ($\alpha > 0{,}5$).
- **Bimodalidad poesía/prosa**: Confirmada y estable.

- **Sin relación con constantes matemáticas**: Descartada tras corrección rigurosa.

El corpus bíblico no se comporta como un corpus lingüístico ordinario, pero sus propiedades atípicas tienen explicaciones causales identificables: heterogeneidad de géneros, tamaño variable de libros, y características específicas de los sistemas de escritura hebreo y griego.

7. Líneas de Investigación Futuras

Las líneas de Fase 2 (Zipf lemas, permutación, V/N, bimodalidad) y las de Fase 3 (dimensión fractal, Zipf por libro del AT, mecanismo de la cuasi-igualdad) fueron **resueltas**. Las siguientes permanecen abiertas:

1. **Análisis espectral**: Aplicar FFT a la serie temporal de valores numéricos por versículo para detectar periodicidades.
2. **Redes de coocurrencia**: Construir grafos de coocurrencia de lemas y analizar propiedades topológicas (clustering, centralidad, comunidades).
3. **Entropía posicional**: Calcular la entropía de Shannon por posición dentro del versículo para cuantificar la "predictibilidad" de cada posición.
4. **Comparación con corpus de control**: Aplicar el mismo pipeline a textos litúrgicos no bíblicos (Corán, Vedas, textos budistas) para determinar qué anomalías son específicas del corpus bíblico y cuáles son propiedades generales de textos sagrados.
5. **Memoria larga por serie temporal**: Aplicar DFA y Hurst a series diferentes (valores numéricos, ratio V/N por versículo) para determinar si la memoria larga es una propiedad de la *longitud* o del *contenido*.
6. **Efecto de tamaño en Zipf**: Cuantificar con subsampling si la anomalía de los profetas menores persiste al normalizar por tamaño de libro (remuestreando n palabras de cada libro).

8. Apéndice: Datos Técnicos

8.1. Gematría hebrea estándar

א=1	ב=2	ג=3	ד=4	=5	=6	=7	=8	=9
=10	=20	=30	=40	=50	=60	=70	=80	=90
=100	=200	=300	=400					

8.2. Repositorio

Todo el código fuente, scripts de análisis y datos están disponibles en:
https://github.com/iafiscal1212/bible_unified

Documento generado automáticamente el 15 de marzo de 2026.
Todos los valores emergen inductivamente del corpus; ningún parámetro hardcodeado.