Bible Unified

Análisis Matemático del Corpus Bíblico Completo

Investigación exploratoria inductiva

Proyecto Bible Research
`github.com/iafiscal1212/bible_unified`

15 de marzo de 2026 — v1.0

Resumen

Se presenta un análisis matemático exploratorio del corpus bíblico completo: 39 libros del Antiguo Testamento en hebreo (Westminster Leningrad Codex) y 27 libros del Nuevo Testamento en griego (SBLGNT/MorphGNT). El corpus unificado contiene **444,339 palabras** con morfología normalizada.

Seis módulos de análisis independientes —frecuencias, morfología, valores numéricos, estructura, coocurrencia y patrones posicionales— se ejecutaron en paralelo sobre los 66 libros. Los resultados revelan anomalías estadísticas significativas: un exponente de Zipf atípico en el AT ($s = 0{,}68$, donde $s \approx 1{,}0$ es el valor canónico), una cuasi-igualdad numérica inesperada entre AT y NT (ratio gematría/isopsefía $\approx 0{,}991$), y asimetrías morfológicas pronunciadas entre los dos corpus.

Todos los valores emergen inductivamente del texto; ningún parámetro está hard-codeado.

Índice

1. Introducción y Contexto **2**
1.1. Principio rector: Análisis inductivo 2
1.2. Corpus 2

2. Metodología **2**
2.1. Arquitectura de paralelismo doble 2
2.2. Módulos de análisis 3
2.3. Infraestructura 3

3. Resultados **3**
3.1. Frecuencias y Ley de Zipf . . . 3
3.1.1. Estadísticas léxicas globales . . . 3
3.1.2. Ley de Zipf . . . 4
3.2. Distribuciones Morfológicas . . . 4
3.2.1. Distribución POS global . . . 4
3.2.2. Asimetría verbo/nombre AT vs. NT . . . 5
3.2.3. Bigramas POS dominantes . . . 5
3.3. Valores Numéricos: Gematría e Isopsefía . . . 5
3.3.1. Sistemas de asignación . . . 5
3.3.2. Resultado principal: Cuasi-igualdad AT/NT . . . 5
3.3.3. Estadísticas por versículo . . . 6
3.4. Análisis Estructural . . . 6
3.4.1. Longitud de versículos . . . 6
3.4.2. Proporciones estructurales AT/NT . . . 7
3.4.3. Libros más grandes . . . 7
3.5. Coocurrencia de Lemas . . . 7
3.5.1. Pares más frecuentes . . . 7
3.6. Patrones Posicionales . . . 8
3.6.1. POS de la primera palabra del versículo . . . 8
3.6.2. POS de la última palabra del versículo . . . 8

4. Discusión: Anomalías y Patrones **8**
4.1. Anomalía 1: Exponente de Zipf del AT ($s = 0{,}679$) . . . 8
4.2. Anomalía 2: Cuasi-igualdad numérica AT/NT . . . 9
4.3. Anomalía 3: Ratio V/N como marcador estilístico . . . 9
4.4. Patrón 4: Ratios jerárquicos crecientes . . . 9

5. Líneas de Investigación Futuras **9**

6. Apéndice: Datos Técnicos **10**
6.1. Gematría hebrea estándar . . . 10
6.2. Repositorio . . . 10

1. Introducción y Contexto

Este proyecto aplica análisis matemático y estadístico al corpus bíblico completo, tratando el texto como un objeto puramente formal: una secuencia de símbolos con estructura jerárquica (palabra $\subset$ versículo $\subset$ capítulo $\subset$ libro $\subset$ corpus).

1.1. Principio rector: Análisis inductivo

No se parte de hipótesis previas sobre qué patrones "deberían" existir. Los módulos de análisis calculan métricas base y dejan que la inspección posterior identifique anomalías estadísticas. Cualquier patrón reportado *emerge* de los datos.

1.2. Corpus

Cuadro 1: Composición del corpus unificado

	AT Hebreo	**NT Griego**	**Total**
Libros	39	27	66
Capítulos	929	260	1,189
Versículos	23,213	7,927	31,140
Palabras	306,785	137,554	444,339
Fuente	WLC (OSHB)	SBLGNT (MorphGNT)	—

Cada palabra del corpus contiene: texto original, lema normalizado, código morfológico, parte del discurso normalizada (POS), y metadatos posicionales (libro, capítulo, versículo, posición).

2. Metodología

2.1. Arquitectura de paralelismo doble

El análisis emplea paralelismo en dos dimensiones:

1. **Por tipo de patrón**: 6 módulos independientes ejecutados como subprocesos simultáneos por el `orchestrator.py`.
2. **Por libro**: Dentro de cada módulo, `multiprocessing.Pool` procesa los 66 libros en paralelo.

2.2. Módulos de análisis

Cuadro 2: Los 6 módulos de análisis

Módulo	Métricas principales
`frequencies`	Frecuencias absolutas/relativas, Zipf, hapax, TTR
`morphology`	Distribuciones POS, ratio V/N, bigramas POS
`numerical`	Gematría hebrea, isopsefía griega, sumas por versículo/capítulo
`structure`	Longitudes, momentos estadísticos, proporciones
`cooccurrence`	Coocurrencia de lemas, PMI (Pointwise Mutual Information)
`positional`	Patrones primera/última palabra, POS por posición

2.3. Infraestructura

- Servidor Hetzner dedicado: 20 cores, 64 GB RAM, Ubuntu 24.04
- Tiempo total de ejecución: **7 segundos** (los 6 módulos en paralelo)
- Dependencias: Python 3.12, NumPy, Pandas, SciPy

3. Resultados

3.1. Frecuencias y Ley de Zipf

3.1.1. Estadísticas léxicas globales

Cuadro 3: Diversidad léxica del corpus

	AT	NT	Global
Tokens (palabras)	306,785	137,554	444,339
Tipos (word-forms)	112,072	19,335	131,407
Tipos (lemas)	9,524	5,461	14,985
Hapax legomena (words)	—	—	90,782
Hapax legomena (lemas)	—	—	5,150
Hapax / tipos (words)	—	—	69.1 %
Hapax / tipos (lemas)	—	—	34.4 %

Observación clave: El 69 % de las formas de palabra aparecen exactamente una vez (*hapax legomena*). El AT hebreo contribuye desproporcionadamente: con 2.23× más tokens, tiene 5.8× más word-types, reflejando la riqueza morfológica aglutinante del hebreo bíblico.

3.1.2. Ley de Zipf

La ley de Zipf predice que la frecuencia de la r-ésima palabra más común es proporcional a r^{-s}, con $s \approx 1{,}0$ para lenguas naturales típicas.

Cuadro 4: Ajuste de Zipf: $\log f = a - s \cdot \log r$

Corpus	**Exponente** s	R^2
Global	0.734	0.918
AT (hebreo)	**0.679**	0.907
NT (griego)	**0.976**	0.962

Anomalía del AT. El exponente $s = 0{,}679$ del AT se desvía significativamente del valor canónico $s \approx 1$. Esto indica una *cola más pesada*: hay proporcionalmente más palabras de frecuencia intermedia de lo que Zipf predice. Hipotesis candidatas:

1. **Morfología aglutinante**: Los prefijos hebreos (*be-*, *ha-*, *we-*) generan múltiples formas de superficie para cada lema, inflando la zona media del ranking.
2. **Vocabulario técnico repetido**: Las secciones legales (Levítico, Deuteronomio) y genealógicas repiten vocabulario especializado con frecuencia intermedia.
3. **Heterogeneidad de género**: El AT mezcla narrativa, poesía, ley y profecía, cada uno con su propio vocabulario, produciendo superposición de distribuciones.

NT canónico. El NT griego ($s = 0{,}976$, $R^2 = 0{,}962$) se ajusta casi perfectamente a Zipf, comportamiento típico de un corpus lingüístico homogéneo.

3.2. Distribuciones Morfológicas

3.2.1. Distribución POS global

Cuadro 5: Distribución de partes del discurso

POS	**Frecuencia**	**%**
Nombre (noun)	148,415	33.4 %
Verbo (verb)	94,088	21.2 %
Sufijo pronominal	47,824	10.8 %
Partícula	28,506	6.4 %
Conjunción	24,605	5.5 %
Preposición	23,908	5.4 %
Pronombre	23,831	5.4 %
Adjetivo	23,194	5.2 %
Artículo	19,770	4.5 %
Adverbio	10,180	2.3 %

3.2.2. Asimetría verbo/nombre AT vs. NT

Cuadro 6: Ratio verbo/nombre por corpus

Corpus	Ratio V/N
AT (hebreo)	**0.55**
NT (griego)	**0.99**
Global	0.63

El AT es fuertemente **nominal** (casi 2 nombres por cada verbo), mientras que el NT tiene equilibrio prácticamente 1:1. Esto refleja:

- AT: estilo genealogico-descriptivo, constructos nominales encadenados (*semikhut*)
- NT: estilo argumentativo-discursivo, oraciones verbales complejas (koiné griega)

3.2.3. Bigramas POS dominantes

El bigrama más frecuente es **nombre→nombre** con 54,207 ocurrencias, reflejando las cadenas de constructo del hebreo (*"hijo-de-David rey-de-Israel"*). El segundo lugar lo ocupa **verbo→nombre** (26,255), el patrón narrativo básico.

3.3. Valores Numéricos: Gematría e Isopsefía

3.3.1. Sistemas de asignación

- **Gematría hebrea**: $\aleph = 1, \beth = 2, \ldots, \tau = 400$ (sistema estándar, formas finales = mismo valor)
- **Isopsefía griega**: $\alpha = 1, \beta = 2, \ldots, \omega = 800$ (sistema clásico con digamma=6, koppa=90)

3.3.2. Resultado principal: Cuasi-igualdad AT/NT

Cuadro 7: Valores numéricos totales por corpus

Corpus	Valor total	
AT (gematría)	78,482,867	
NT (isopsefía)	79,203,470	
Ratio AT/NT	**0.9909**	
Diferencia	720,603	(0.91 %)

Interpretación. A pesar de que el AT tiene 2,23× más palabras que el NT, los valores numéricos totales son prácticamente idénticos (diferencia $< 1\,\%$). Esto ocurre porque el alfabeto griego asigna valores más altos (máximo $\omega = 800$) que el hebreo (máximo $\tau = 400$), compensando exactamente la menor cantidad de texto.

Pregunta abierta: ¿Es esta cuasi-igualdad una consecuencia trivial de las proporciones alfabéticas, o existe una invariancia más profunda? Un test de permutación (bootstrap) puede distinguir ambas hipótesis.

3.3.3. Estadísticas por versículo

Cuadro 8: Valores numéricos por versículo (global)

Métrica	**Valor**
Número de versículos	31,140
Media	5,063.8
Mediana	3,855
Mínimo	160
Máximo	32,312
Percentil 25	2,376
Percentil 75	6,386

3.4. Análisis Estructural

3.4.1. Longitud de versículos

Cuadro 9: Momentos estadísticos de la longitud de versículo (en palabras)

Momento	**Valor**
Media (μ)	14.27
Mediana	13
Desviación estándar (σ)	6.44
Asimetría (skewness)	+0.76
Curtosis (excess)	+0.53
Mínimo	2
Máximo	58
P10	7
P90	23

La distribución tiene asimetría positiva ($\gamma_1 = 0{,}76$): cola derecha extendida. La curtosis ligeramente positiva ($\kappa = 0{,}53$) indica un pico más agudo que la distribución normal, con colas algo más pesadas.

3.4.2. Proporciones estructurales AT/NT

Cuadro 10: Proporciones entre AT y NT

Métrica	**AT**	**NT**	**Ratio AT/NT**
Palabras	306,785	137,554	2.230
Versículos	23,213	7,927	2.928
Capítulos	929	260	3.573

Patrón jerárquico. Los ratios AT/NT crecen al subir en la jerarquía: 2,23 → 2,93 → 3,57 (palabras → versículos → capítulos). Esto implica que los versículos del NT son en promedio más largos (17.35 palabras/verso) que los del AT (13.22 palabras/verso), y los capítulos del NT contienen más versículos.

3.4.3. Libros más grandes

Cuadro 11: Top 5 libros por número de palabras

#	**Libro**	**Palabras**
1	Jeremías	21,976
2	Génesis	20,629
3	Salmos	19,657
4	Lucas	19,446
5	Ezequiel	18,866

3.5. Coocurrencia de Lemas

Se analizaron 688,150 pares únicos de lemas que coocurren en al menos un versículo.

3.5.1. Pares más frecuentes

Cuadro 12: Top 10 pares de lemas coocurrentes (por frecuencia)

#	**Lema A**	**Lema B**	**Coocurrencias**
1	*kai* (y)	*ho* (el)	4,568
2	*autos* (él)	*ho* (el)	3,427
3	*autos* (él)	*kai* (y)	2,735
4	*de* (pero)	*ho* (el)	2,245
5	YHWH (3068)	*'et* (853)	2,125
6	*'el* (a) [413]	*'amar* (dijo) [559]	2,107
7	*'asher* (que) [834]	*'et* (853)	2,001
8	*en* (en)	*ho* (el)	1,912
9	*eimi* (ser)	*ho* (el)	1,868
10	*lego* (decir)	*ho* (el)	1,826

Los pares del NT dominan el ranking global debido a la alta frecuencia del artículo *ò* en griego. En el AT, el par dominante es YHWH + marcador de objeto directo (*'et*), reflejando la construcción "[verbo] a YHWH".

3.6. Patrones Posicionales

3.6.1. POS de la primera palabra del versículo

Cuadro 13: POS de la primera palabra de cada versículo

POS	**Frecuencia**	**%**
Verbo	12,668	40.7 %
Nombre	4,977	16.0 %
Conjunción	4,245	13.6 %
Partícula	2,265	7.3 %
Pronombre	1,478	4.7 %
Sufijo	1,477	4.7 %
Adverbio	1,423	4.6 %

Patrón narrativo. El 40.7 % de los versículos comienzan con un **verbo**, reflejando la estructura *wayyiqtol* del hebreo narrativo ("Y dijo...", "Y fue...") y construcciones similares en el NT griego. Esto es un rasgo tipológico fundamental del estilo bíblico.

3.6.2. POS de la última palabra del versículo

Cuadro 14: POS de la última palabra de cada versículo

POS	**Frecuencia**	**%**
Nombre	12,810	41.1 %
Sufijo pron.	7,090	22.8 %
Verbo	6,138	19.7 %
Pronombre	2,398	7.7 %
Adjetivo	1,980	6.4 %

Complementariedad posicional. Existe una clara **complementariedad**: los versículos *abren con verbo* (40.7 %) y *cierran con nombre* (41.1 %) + sufijo pronominal (22.8 %). La preposición casi nunca cierra un versículo (0.02 %), como era esperable.

4. Discusión: Anomalías y Patrones

4.1. Anomalía 1: Exponente de Zipf del AT ($s = 0{,}679$)

El valor canónico $s \approx 1{,}0$ se observa en la mayoría de los corpus de lenguas naturales. El AT hebreo se desvía con $s = 0{,}679$, lo cual es inusual. La desviación no se observa en el NT griego ($s = 0{,}976$).

Hipótesis principal: La morfología aglutinante del hebreo bíblico —donde prefijos (*be-*, *ha-*, *we-*, *le-*) se adhieren a las raíces— genera un número desproporcionado de formas de superficie únicas, inflando la zona media del ranking de frecuencias y aplanando la pendiente de Zipf.

Test sugerido: Recalcular Zipf sobre *lemas* en lugar de word-forms. Si el exponente se acerca a 1.0 al usar lemas, la hipótesis morfológica queda confirmada.

4.2. Anomalía 2: Cuasi-igualdad numérica AT/NT

El ratio de valores totales gematría(AT)/isopsefía(NT) es 0,9909, es decir, los valores son prácticamente idénticos a pesar de:

- El AT tiene 2,23× más palabras
- Los alfabetos tienen rangos de valores diferentes (hebreo: 1–400, griego: 1–800)
- Los textos fueron escritos en diferentes siglos y lenguas

Test sugerido: Bootstrap/permutación. Generar $N = 10{,}000$ corpus aleatorios con las mismas distribuciones de caracteres pero con longitudes permutadas, y comparar el ratio AT/NT observado con la distribución nula.

4.3. Anomalía 3: Ratio V/N como marcador estilístico

El salto de V/N = 0,55 (AT) a V/N = 0,99 (NT) es drástico. Dentro del AT, es probable que haya variación significativa por género literario (narrativo vs. poético vs. legal). Mapear V/N por libro puede revelar clusters de autoría o época.

4.4. Patrón 4: Ratios jerárquicos crecientes

Los ratios AT/NT crecen monótonamente con el nivel jerárquico:

$$\frac{\text{AT}}{\text{NT}} = \begin{cases} 2{,}230 & \text{(palabras)} \\ 2{,}928 & \text{(versículos)} \\ 3{,}573 & \text{(capítulos)} \end{cases}$$

Esto implica que la "densidad" de texto disminuye al subir en la jerarquía del NT respecto al AT: los versículos del NT son más largos y los capítulos contienen más versículos, de manera consistente.

5. Líneas de Investigación Futuras

1. **Zipf sobre lemas vs. formas**: Separar el efecto morfológico del efecto semántico en la anomalía de Zipf del AT. Si $s_{\text{lema}} \approx 1{,}0$, la desviación es puramente morfológica.
2. **Test de permutación para la igualdad numérica**: Determinar si el ratio $\approx$ 0,991 es estadísticamente significativo o una consecuencia trivial de las proporciones alfabéticas.

3. **Mapa V/N por libro**: Correlacionar el ratio verbo/nombre con la datación propuesta, género literario y autoría. Posible uso como "fingerprint" estilístico.
4. **Distribución de longitud de versículos por género**: Investigar la posible bimodalidad (picos en 7 y 12–13 palabras) y su correlación con narrativa vs. poesía vs. ley.
5. **Análisis espectral**: Aplicar FFT a la serie temporal de valores numéricos por versículo para detectar periodicidades.
6. **Redes de coocurrencia**: Construir grafos de coocurrencia de lemas y analizar propiedades topológicas (clustering, centralidad, comunidades).
7. **Entropía posicional**: Calcular la entropía de Shannon por posición dentro del versículo para cuantificar la "predictibilidad" de cada posición.

6. Apéndice: Datos Técnicos

6.1. Gematría hebrea estándar

א=1	ב=2	ג=3	ד=4	=5	=6	=7	=8	=9
=10	=20	=30	=40	=50	=60	=70	=80	=90
=100	=200	=300	=400					

6.2. Repositorio

Todo el código fuente, scripts de análisis y datos están disponibles en:
https://github.com/iafiscal1212/bible_unified

Documento generado automáticamente el 15 de marzo de 2026.
Todos los valores emergen inductivamente del corpus; ningún parámetro hardcodeado.